

基于 RK3588 与深度学习的非侵入式电池识别与 火灾检测充电桩

雪流星队；徐宏杰；李心宇；殷成雨；周磊

摘要

近年来，电动自行车引起的火灾事故频发，严重威胁人民生命财产安全。特别是今年发生在南京雨花区的“2.23”火灾事故，由电动自行车在架空层充电起火引发，造成 15 人死、44 人伤，数百户家庭受影响的严重后果。4 月 13 日李强总理在国务院会议上专门部署电动自行车安全隐患整治工作。

本项目围绕电动自行车充电安全与用电行为智能识别，设计并实现了一套集非侵入式负载识别、火焰智能检测于一体的智能监测系统。系统通过自主设计的硬件平台实现对电压、电流等参数的高精度采样特征提取，在无需改造现有充电架构的前提下，精准识别锂电池与铅酸电池运行状态及其差异性特征，有效监测故障电弧、异常漏电等潜在安全隐患。

模型架构方面，系统创新性地采用非参数统计方法与深度神经网络相结合的双分支识别策略。前者具备响应速度快、适用于边缘部署的特点，用于初步识别与数据聚类分析；后者利用大量采集数据进行训练优化，增强模型的泛化能力与识别精度，并实现对初步结果的修正补偿。针对火灾识别的实时性需求，系统基于国产 RK3588 高性能处理器，在边缘端部署轻量级火焰检测模型，实现毫秒级响应与本地报警，有效规避灯光反射、衣物图案等误识别干扰，显著提升了识别鲁棒性。

在系统软件平台方面，项目构建了一个高并发、高可靠的分布式数据处理架构，融合消息队列、负载均衡机制和视频流低延迟传输技术，保障了各类监测数据在采集、传输、存储与响应过程中的稳定性与实时性。同时，平台提供了面向用户与管理者的多终端交互界面，支持智能控制、可视化展示和现场状态实时查看，全面提升了用户体验与系统实用性。

该系统为电动自行车分类安全管理提供了智能化数字化手段，并已经过

多地长期验证，效果良好，目前已受到多家电动自行车充电运营企业和管理单位的青睐，正在大面积展开推广工作。

第一部分 作品概述

1.1 功能与特性

系统通过非侵入式负载识别与火焰智能检测一体化设计，有效解决电动自行车充电安全隐患。硬件平台实现了高精度电压/电流采样，无需改造现有充电架构，即可精准区分锂电池与铅酸电池，并实时识别故障电弧、异常漏电等关键危险信号。算法采用创新的双分支架构：在边缘端部署非参数统计方法实现风险信号的毫秒级快速响应，同时利用基于 TimesNet 的深度学习模型持续优化识别精度。同时，在边缘端基于高性能 RK3588 处理器部署轻量级 YOLOv11 火焰检测模型，实现毫秒级火焰识别响应，并有效抵抗环境灯光反射等干扰，显著提升火灾预警能力。软件平台集成分布式架构保障系统扩展性，利用消息队列（RabbitMQ）实现模块间高效、可靠通信，并通过低延迟视频流（RTMP）技术实现实时火焰视频监控与分析，确保系统具备高并发数据处理能力。其核心系统架构图（图 1-1）清晰展示了终端感知层、边缘计算层与云端智能分析层构成的完整物联网三层结构，实现了从数据采集、边缘处理到云端决策的闭环管理，为电动自行车充电安全提供了全方位的技术保障。

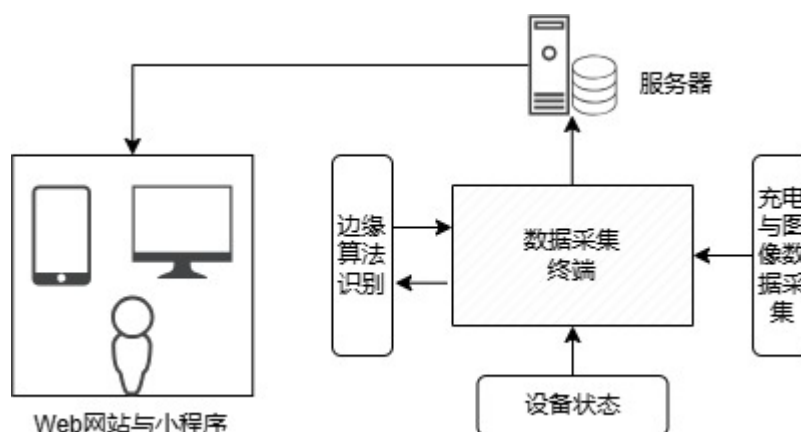


图 1-1

1.2 应用领域

当前电池的热失控是导致火灾发生的主要原因，尤其是锂离子电池在受

到机械损伤、过充过放、内部短路或环境温度异常等影响时，极易发生热失控反应，进而导致起火甚至爆炸^[1]。

本系统聚焦电动自行车集中充电的高危场景，如居民区架空层、地下车库，以及公共充电站、商业场所充电桩等安全管理难点，为政府与物业推动的电动自行车“全链条整治”提供关键的技术防范手段。其核心价值在于：替代低效人工巡查，通过精准识别锂电池与铅酸电池（隔离高风险锂电池充电），实现电池类型智能分类管理；同时，系统将安全防线大幅前移，从传统的“事后灭火”彻底转向“事前预警”，通过毫秒级识别故障电弧、异常漏电、初期火焰，有效解决传统消防响应滞后问题，显著降低火灾风险。

1.3 主要技术特点

本系统在硬件采用霍尔电流互感器（HCS-ES5-75A）进行电流采样，支持高达高频数据采集，确保能精准捕捉电流变化细节，适用于动态响应要求较高的场景。同时，系统集成 HLW8110 高精度电量计量芯片，具备±1%的计量误差，进一步提升了整体能耗监测的可靠性和稳定性。在算法层面，融合非参数统计与深度学习方法，通过 HDBSCAN 聚类实现无监督的异常识别，再结合 TimesNet 进行高维时序建模，有效提高非侵入式识别的精度与鲁棒性。在火焰检测模块中，采用 YOLOv11n 目标检测模型，引入 C3K2 与 C2PSA 模块，在保持轻量化部署的前提下显著提升检测精度和响应速度。系统架构采用边缘-云协同策略，边缘端部署基于 RK3588 高性能处理器，负责现场的实时推理任务，满足低延迟要求；而云端以 Spring Boot 构建微服务体系，结合 Redis 实现高效缓存管理，不仅支持数据可视化展示，还通集成大语言模型，实现对设备状态的智能问答与辅助决策功能。整体方案实现了从硬件采集到智能分析的闭环，具备实时性、智能性与可扩展性。

1.4 主要性能指标

表 1-1 主要性能指标

指标	数值
电流采样范围	0-75A
采样频率	6400Hz

电池类型识别准确率	>97%
火焰检测响应延迟	$\leq 20\text{ms}$
电池类型识别延迟	$\leq 20\text{ms}$
视频流传输延迟	$< 1000\text{ms}$
支持并发充电桩数	≥ 1000 个

1.5 主要创新点

1. 基于深度学习结合非参数方法，实现交流侧充电识别与电池类型判别，无需直流端侵入式设备，安装便捷、兼容性强。
2. 无感故障检测与端侧电池动态感知机制，检测电弧、短路等故障特征；基于 RK3588 边缘平台部署轻量模型，实现火焰实时识别与报警，保障安全闭环控制。
3. 多端智能管理平台支持 PC、移动端、小程序查看电池状态、历史记录与预警，采用分布式架构和低延迟视频流，保障高效数据传输与系统稳定性。
4. RAG 智能问答系统融合云端大模型、企业知识库与 RAG 框架，实现智能问答、工具调用和多轮对话，提升用户安全认知与管理能力。

1.6 设计流程

首先，针对交流侧充电识别与电池类型判别需求，采用深度学习结合非参数方法，规避直流端侵入式设备，提升安装便捷性与兼容性。其次，设计无感故障检测与电池动态感知机制，构建轻量模型识别电弧、短路等特征，在 RK3588 边缘平台部署，实现火焰实时检测与报警，确保安全闭环控制。随后，开发多端智能管理平台，基于分布式架构和低延迟视频流，实现 PC、移动端、小程序对电池状态、历史记录与预警的高效访问。最后，结合云端大模型、企业知识库与 RAG 框架，构建智能问答系统，支持多轮对话，提升用户安全认知和管理能力。整体流程注重算法优化、边缘算力适配与系统稳定性，确保安全、高效和智能的管理体验。

第二部分 系统组成及功能说明

2.1 整体介绍

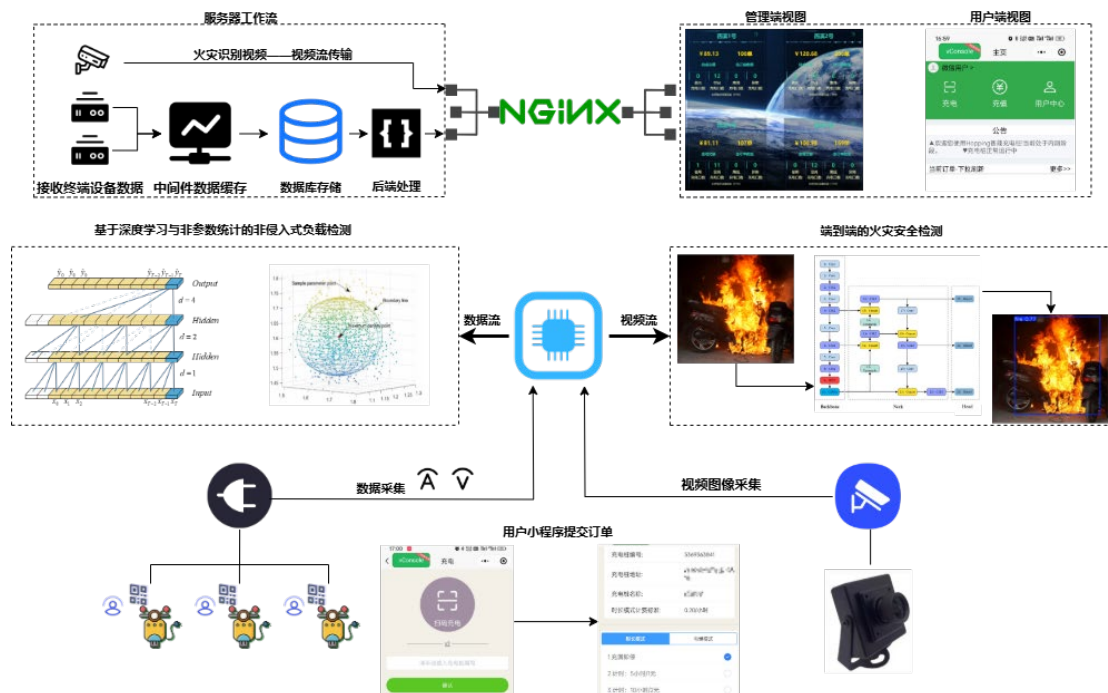


图 2-1 系统总体框架

如图 2-1 所示系统围绕电池火灾防控痛点，提出基于交流侧非侵入式识别与实时预警的整体需求，设计分层架构包括终端传感器采集、边缘 AI 推理及云端数据管理，实现端到端的安全闭环。硬件选型采用国产 DSP 处理器、HLW8110 高精度电量计量芯片与霍尔传感器，兼顾性能与成本。算法层面，非侵入识别模块融合 HDBSCAN 聚类与 TimesNet 时序映射，实现电池类型与状态精准判别；火焰检测模块通过 YOLOv11n 模型，适配 RK3588 边缘计算平台，实现高效推理与快速响应。软件平台采用微服务容器化部署，结合消息队列实现异步通信与高并发处理，支撑多终端数据接入、实时预警和智能管理，形成完整的软硬件协同解决方案。

2.2 硬件系统介绍

2.2.1 硬件整体介绍；

硬件设计的主要目标是实现对电动自行车充电过程的实时监控和管理,确保




图 2-2 系统的硬件电路设计框图

系统的安全性、可靠性和高效性。系统的硬件电路设计框图如图 2-2 所示,原理图如图 2-3 所示,模型图如图 2-4 所示。

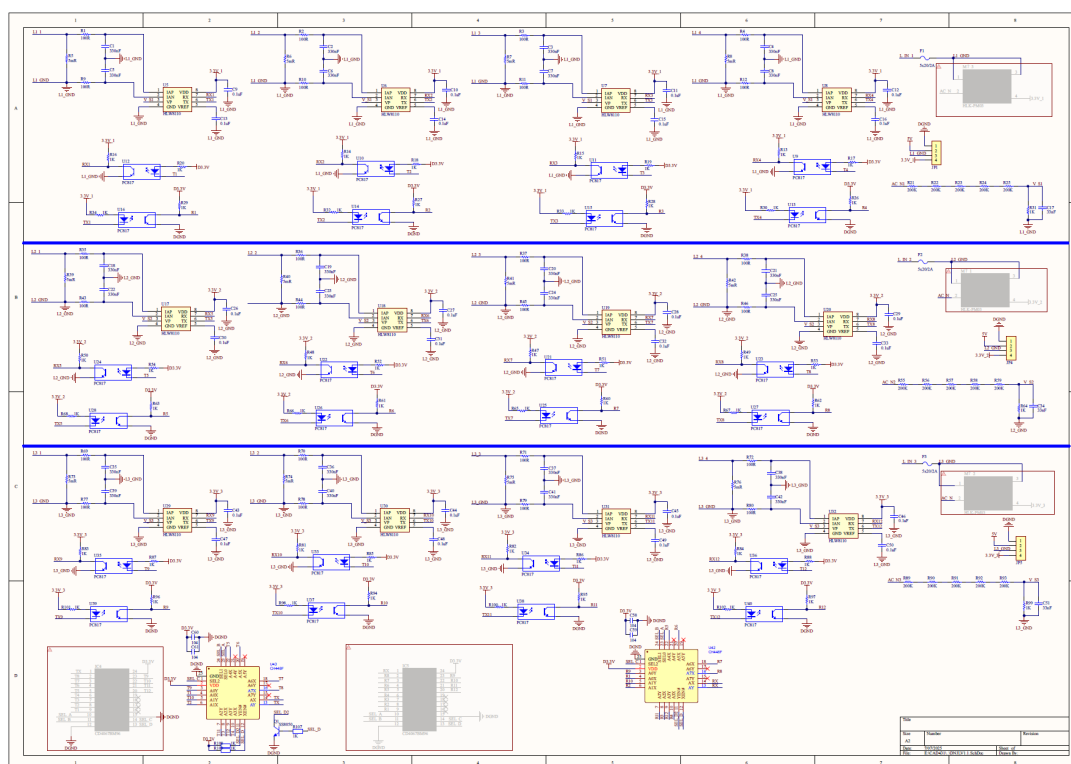


图 2-3 电路原理图




图 2-4 3D 效果图

为实现本智能充电桩的分类识别，需要在充电桩控制电路之前接入检测识别电路，实现检测输出的 12 路充电接口的接入电动自行车类型，完成分类管理功能。并且采用 HLW8110 高精度电能计量 IC，此器件内部集成了个高精度的电能计量内核，用于单相交流应用或直流信号，其精度范围为 $\pm 1\%$ 。可以完成精准的充电电量计量，控制电路采用了磁保持继电器来满足大功率电路的控制与实现。

霍尔电流互感器采样电路

霍尔电流互感器采样电路在整个系统中起着至关重要的作用，是实现电动自行车识别与分类的核心组成部分。其主要功能是对线路中的电流信号进行精准采集，并通过滤波与调理电路对原始信号进行处理，以增强信号的稳定性、抑制噪声干扰，将信号幅度调整至适合 ADC 采样的范围，为后续的数据处理模块提供高质量的输入数据。




图 2-5 HCS-ES5-75A 的输出曲线

获取到充电线路的真实电流波形是进行用电安全分析的前提。本系统采用 HCS-ES5-75A 霍尔传感器将连续的电流信号转换为电压信号，相较于普通 CT 有很高的频率测量范围，且能够真实、高精度的反映电流波形。本系统选用传感器可测量程为 0-75A，输出 $2.50 \pm 0.625V$ 的线性直流电压，其输出曲线如图 2-5 所示。

图 2-5 为当电流范围-75A~75A 之间的电压输出曲线，线路电流与霍尔传感器的输出电压呈线性关系。因此，霍尔传感器的输出电压与线路电流关系如式 2.1。

$$V_{out} = \frac{I \cdot 1.125V}{150A} + 2.5V \quad (2.1)$$

将互感器输出电压转换成数字量，可以计算出互感器的输出电压，由数字量计算出电压 $V(i)$ 如式 2.2。

$$V(i) = \frac{d(i) \cdot V_{ref}}{2^{12} - 1} \quad (2.2)$$

其中， V_{ref} 为 A/D 转换器的参考电压，本系统中 $V_{ref} = 3.3V$ 。推导出采样点的电压 $V(i)$ 到供电线路实际电流的转化公式如式 2.3。

$$I(i) = V(V(i) - V_0) \cdot \frac{I_{max}}{\Delta V} \quad (2.3)$$

其中 V_0 是线路电流为 0 时互感器的电压输出电压， I_{max} 是互感器的最大可测量电流， ΔV 是互感器线性输出电压的最大变化值。电路原理图如图 2-6 所示。

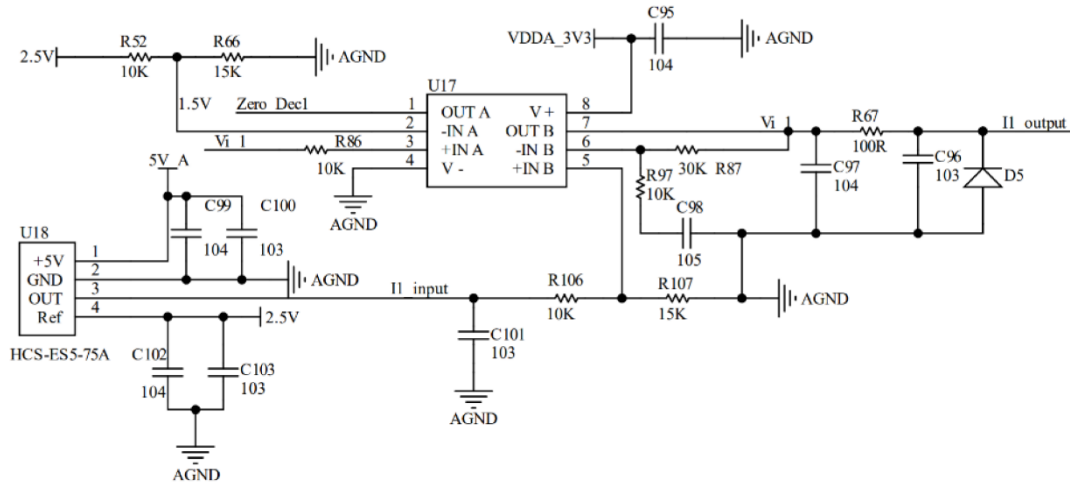


图 2-6 电流采集电路

国内居民用电标准为 220V、50Hz 的正弦交流电，因此本系统在采集电流波形时，以一个工频周期内采集 128 个样本点，得到的采样频率为 6400Hz。考虑到电力负载的主要谐波成分通常集中在前 15 次谐波以内，即最高频率为 750Hz。根据奈奎斯特采样定理，为防止混叠现象，采样频率应至少为最高频率的两倍，即 $\geq 1500\text{Hz}$ 。系统所采用的 6400Hz 采样率远高于此标准，能够完整保留电流信号中前 15 次谐波成分的特征信息，满足后续的波形分析与负载识别算法对数据精度的要求。

电量采集电路（HLW8110）

电路的有功功率通过获取 HLW8110 数据进行计算，其有功功率计算公式如式 2.4。

$$P = \frac{PowerPA \cdot PowerPAC}{K1 \cdot K2 \cdot 2^{31}} \quad (2.4)$$

其中 PowerPA 表示通道 A 的有功功率有效值，PowerPAC 为通道 A 的有功功率转换系数，K1 为电流系数，K2 为电压系数。电流数据计算如式 2.5。

$$E = \frac{EnergyPA \cdot EnergyPAC \cdot HFconst}{K1 \cdot K2 \cdot 2^{29} \cdot 4096} \quad (2.5)$$

其中 EnergyPA 表示通道 A 的有功电能有效值、EnergyPAC 表示通道 A 的有功电能转换系数，HFconst 为脉冲频率。电路图如图 2-7 所示。

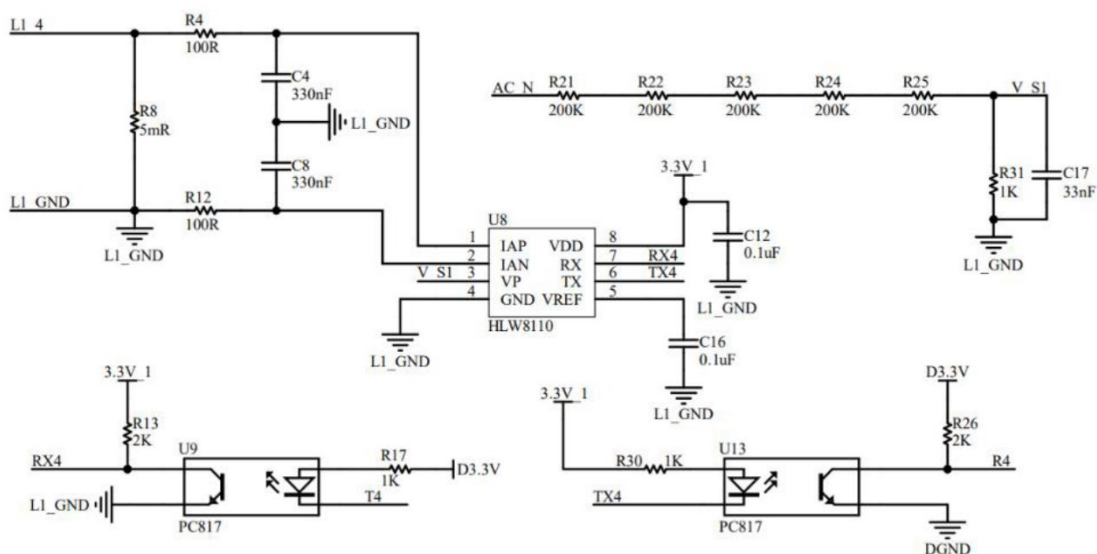


图 2-7 HLW8110 硬件电路

2.3 软件系统介绍

2.3.1 软件整体介绍

本系统基于面向 AI 模型的分布式架构设计，构建了一个高效、灵活、可扩展的智能服务平台，应用于电动自行车电池识别与用电行为监控等场景。整个系统由电动自行车电池 AI 智能识别系统和用电行为数据监控平台两大子系统组成，通过边缘计算与云计算协同、通信与存储分层设计，实现了边缘 AI 模型的高效部署与实时推理数据传输，系统框架如图 2-8。

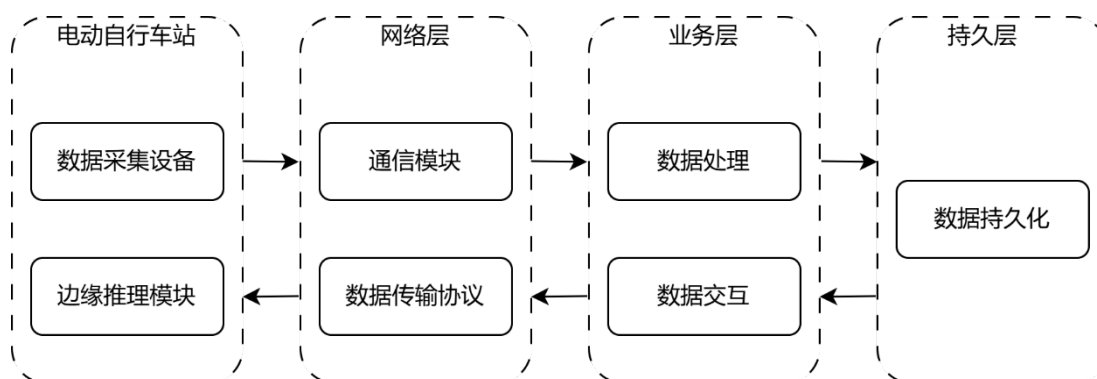


图 2-8 面向边缘 AI 模型的分布式系统框架

在该框架中，通过嵌入式设备采集充电数据，并执行轻量级的预处理。采集数据在边缘设备上完成复杂模型的推理与识别任务，经过通信模块将识别后的结果和采集到的数据传输至中心服务器，服务器上的各服务采用微服务架构并通过容器进行管理。

为了满足海量数据处理和实时反馈的要求，平台采用分布式数据处理技术构建行为分析与特征建模子系统，能够对用户的用电行为数据进行实时监控和趋势分析，识别异常模式。

整套架构强调模块解耦与任务分布，不仅提升了系统在大规模部署场景下的稳定性与可维护性，也适应了边缘 AI 模型应用和系统的功能扩展提供了技术基础。该框架适应电动自行车电池识别的具体业务需求，体现了面向 AI 模型的分布式系统框架设计理念与工程实践的深度融合。

2.3.2 软件各模块介绍

非侵入用电器检测模型结构与流程

非侵入式负载识别主要分为符合特征提取和分类器识别不同的电器设备，不同的特征提取方法和负载识别算法对识别结果的影响不同。在非侵入式负载监测(NILM, Non-Intrusive Load Monitoring)的早期是通过提取负载的有功功率和无功功率来进行分类^[2]。随着研究的不断深入，特征提取的方法逐步多样化，不再局限于有功功率和无功功率、功率变化率等传统参数，而是逐渐引入了频域分析，通过傅里叶变化获取谐波特征^[3]、开关事件瞬态波形变化^[4]以及电流电压轨迹(V-I

Trajectory)^[5]等。这些特征的提取使得对复杂识别成为可能，也为提高整体系统的识别准确率与稳定性奠定了基础。

首先，部署在充电站的数据采集终端待订单开启后进行负载数据初步采集，并在本地对原始信号进行简单预处理，包括去噪、初步特征提取、与时序切分等操作。由于深度学习模型需要采集足够的数据，为了实现实时响应与快速判别，系统在边缘侧首先采用非参数统计方法对当前负载变化进行快速识别，基于非参数的初步分类模型，用于快速判断负载类型。这一阶段的识别结果虽相对粗略，但具备实时性高、计算资源消耗小的优势，适合部署在边缘设备中。待收集足够的数据再对负载类型进行最终判别。

同时，终端会不断积累大量用电行为数据及其对应的初步识别结果，并周期性地同步至云端服务器。云平台汇总多个终端上传的数据，基于已识别的事件进行特征学习，进而训练更为复杂的深度学习模型，与优化非参数方法的先验知识，从而显著提升整体识别准确率。

在模型训练与更新过程中，系统将利用云端存储的历史数据与识别标签，通过聚类算法对非参数模型的关键参数进行持续优化，提升边缘模型在初始阶段的识别效果，模型框架如图 2-9 所示。

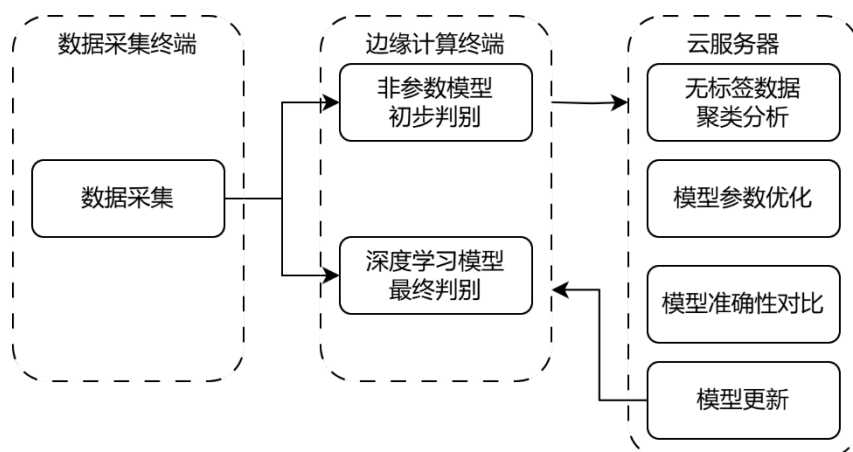


图 2-9 模型推理与优化流程

整体流程体现了边缘快速响应与云端深度分析的协同策略，实现了在不增加用户硬件负担的前提下，对负载进行高效、精准的非侵入识别。

面向 AI 模型的分布式软件架构设计

本系统的服务端软件架构带来的最大优势是模块化和独立部署。将系统分解为多个微服务，每个服务专注于单一功能，能够独立开发、测试和部署，极大地提高了系统的灵活性和可维护性。各个微服务又可以独立扩展，根据业务需求调整规模，提高资源利用效率。

其次，性能优化和系统扩展也是这种架构的显著优势。**Redis** 作为高性能的缓存数据库，通过缓存机制减少了对数据库的访问频率，大幅提升了数据读取速度，优化了系统性能。**Redis** 还支持分布式缓存，能够轻松应对高并发请求。此外，中间件如消息队列的引入，可以实现异步消息处理，解耦服务之间的依赖，进一步提高系统的响应速度和可靠性。

在高可用性和容错方面，微服务独立部署，如果某个服务出现故障，不会影响到整个系统的运行。中间件如消息队列可以保证消息的持久化和可靠传递，增强系统的容错能力。**Redis** 提供的数据持久化选项和高可用性配置，如 **Redis Sentinel** 和 **Cluster** 模式，确保了数据的可靠性和一致性。

本系统的架构完美的解决了各个服务之间的通信与协调问题。微服务需要有效的服务注册与发现机制，确保服务能够互相通信，同时还需要配置负载均衡，保证请求合理分配到各个服务实例。采用事件溯源、CQRS 等模式，保证了数据在分布式系统中的一致性。同时，确保了 **Redis** 缓存数据与数据库的一致性，避免数据不一致问题。

本系统故障处理需要考虑网络延迟、服务不可用等问题，需要实现熔断、重试、限流等机制。本系统的分布式日志管理和监控系统也十分完善，用于实时监控服务状态，快速定位和解决问题。

性能优化方面，需要设计合理的缓存策略，确定哪些数据适合缓存，设置合适的缓存过期时间，避免缓存击穿、雪崩等问题。同时，消息队列的吞吐量和延迟优化也得到了优化，以确保在高并发场景下的稳定性能

安全性也是不可忽视的部分。确保微服务之间的通信安全，使用 **TLS/SSL** 加密和身份认证机制是基本要求。**Redis** 缓存中的数据安全同样需要保障，设置访问控制和权限管理是必须的。

基于边缘计算的智能硬件的软件架构设计

用户层软件主要由电流数据采集监控软件、网络通信软件以及主任务软件三个模块组成，它们运行于驱动层之上，驱动层主要调用硬件接口完成与硬件的交互。主任务软件负责协调和调度采集监控模块和通信模块。用户层软件属于前后台软件系统，所谓前后台系统，即通过中断、定时器和主循环完成程序模块的任务调度与数据交互。在终端中，电量数据采集监控软件和网络通信软件被主任务软件通过定时器、中断等方式进行合理的调度共同完成智能监控终端的软件功能。

(1) 采集与监控模块：电压、电流、电量、功率数据采集与监控模块主要通过计量芯片的读写来定时采集用电行为的数据，再通过高精度电流采集电路获取用电电流信号，进行一定数字信号处理，再传至云端完成识别计算。

(2) 网络通信模块：网络通信软件主要完成与云端的网络通信，保持与云端的长连接，将本地的数据打包发送到云端，同时接收云端的控制信号。

(3) 主任务软件模块：主任务软件主要负责调度和协调采集模块和网络通信模块，边缘计算以及处理定时器和中断等任务。

非参数统计方法与聚类算法原理分析

在本系统中，针对采集信号所包含的瞬态特征与稳态特征，采用了一种基于非参数统计的分析方法。该方法无需依赖特定的概率分布假设，能够在保持数据原始特性的基础上，结合已有知识进行样本间的相似性判断。通过对特征间差异性的综合评估，实现了对输入数据的有效识别与分类，为后续的智能决策与模式识别提供支持。

为了对比待测样本与先验知识库中样本的相似性，本系统中引入了余弦相似度作为主要度量方式。余弦相似度如式 2.6。

$$Similarity(A, B) = \frac{A \cdot B}{\|A\| \times \|B\|} = \frac{\sum_{i=1}^n (A_i \times B_i)}{\sqrt{\sum_{i=1}^n A_i^2} \times \sqrt{\sum_{i=1}^n B_i^2}} \quad (2.6)$$

为了优化先验知识库，我们引入了无监督学习策略，将采集到的无标签数据通过 DBSCAN (Density-Based Spatial Clustering of Applications with Noise) 方法实现聚类，对采集到的无标签数据进行结构化整理。通过识别数据中的潜在模式

和类别结构，使得知识库能够自适应地更新并增强对新样本的覆盖能力，从而提升整体匹配与识别的准确性

DBSCAN 是一种基于密度的无监督聚类方法，具有较好的适应性与鲁棒性。与传统聚类算法相比，DBSCAN 能够在没有预先设定簇数的前提下，根据数据本身的分布结构自动识别聚类结果。这一特性尤其适用于处理结构复杂或类别数量未知的实际应用场景。其核心机制通过构建数据的最小生成树，并基于局部密度特征进行簇的划分，同时能够有效检测并剔除数据中的离群点，从而增强聚类结果的纯净度。DBSCAN 对非球状、不规则分布的簇结构也具备良好的识别能力，适用于高维数据、噪声数据或聚类边界模糊的复杂场景。系统引入 DBSCAN 可以从无标签样本中挖掘潜在的类别关系，为后续的特征匹配与模型训练提供更具代表性的先验知识支持。DBSCAN 的伪代码如下。

HDBSCAN 的伪代码

输入：

$$D = \{x_1, x_2, \dots, x_n\}$$

minPts (minimum points)

输出：

$$C = \{C_1, C_2, \dots, C_k\}$$

Noise

步骤：

1. 计算核心距离 (core-distance)

对于每个点 $x \in D$ ：

$\text{dist_to_neighbors} \leftarrow$ 与 x 最近的 minPts 个点的距离集合

$\text{core_dist}[x] \leftarrow$ 第 minPts 小的距离值

2. 构造互达距离图 (Mutual Reachability Graph)

初始化完全 G ，其中每条边 (i, j) 的权重：

$$\text{mreach_dist}^{(i, j)} = \max\{\text{core_dist}[i], \text{core_dist}[j], d(i, j)\}$$

3. 生成最小生成树 (Minimum Spanning Tree, MST)

MST \leftarrow 在 G 上运行 Prim 算法，按边权从小到大连接

4. 构建单链接层次聚类树 (Single-Linkage Dendrogram)

初始化 Union-Find 结构 UF，所有点各自为一组

edges_sorted \leftarrow 按 mreach_dist 升序排列的 MST 边列表

for each edge $e = (i, j)$ in edges_sorted do

$d_e \leftarrow \text{mreach_dist}(i, j)$

UF.union(i, j)

记录合并事件：在距离 d_e 时，两个簇合并

5. 凝聚树 (Cluster Condensation)

构造每个簇的存活区间 $[\lambda_{\text{death}(x)}, \lambda_{\text{death}(x)}]$ ，其中 $\lambda = 1 / \text{distance}$

对于每个簇：

$$\text{stability} = \sum (\lambda_{\text{death}(x)} - \lambda_{\text{birth}(x)})$$

删除稳定性小于阈值（通常自动确定）的簇节点

6. 提取最终簇 (Extract Flat Clusters)

从凝聚后的树上选择具有最大稳定性的若干簇

对于剩余的未归类点，标记为 Noise

7. 输出簇标签和噪声点

DBSCAN 聚类结果经 PCA 降维后进行可视化，如图 2-10 所示。可见该方法不仅能够清晰地区分不同簇结构，同时有效识别并剔除噪声点。




图 2-10 HDBSCAN 聚类可视化结果

基于 TimesNet 的非侵入式用电器识别分析

采集到的用电器波形具有明显的周期性，本系统为了捕捉时间序列的多周期性，采用 TimesNet 作为深度学习模块，TimesNet 将复杂的时间变化划分为多个周期内和周期间的变化。同时为了解决一维时间序列在表示能力上的局限性，模型将一维的时间序列转化为多个周期的二维数据。通过将时间变化转换为基于多个周期的一组二维张量从而将周期变化分别嵌入到二维张量的行和列中，从而更容易捕捉其中的特征。Times Block 可以自适应的发现数据中的周期性，从而捕捉时间序列中的复杂特征。其在多个任务领域都有较好的表现。

一维时序变量映射为二维机制

对于长度为 T , 变量数为 C 的序列 $X_{1D} \in \mathbb{R}^{T \times C}$ 。为了发现序列中的周期间变化需要先找到其周期特征。模型使用快速傅里叶变换(Fast Fourier Transform, FFT)如式 2.7 所示。

$$A = \text{Avg}(\text{Amp}(\text{FFT}(X_{1D}))), \{f_1, \dots, f_k\} = \arg \text{Top}k, p_i = \begin{bmatrix} T \\ f_i \end{bmatrix}, i \in \{1, \dots, k\} \quad (2.7)$$

其中 $FFT(\cdot)$ 为快速傅里叶变换， $Amp(\cdot)$ 为计算幅值。A 表示 C 维变量平均计算后的各频率幅值。 A_j 表示第 j 个频率分量的周期性基函数强度，该频率对应的周期为 T/J 。同时考虑到频谱密度的稀疏性，为了避免噪声干扰，仅选取 Top k 个幅值，从而得到最重要的频率分量。考虑到频率的共轭性，只考虑频率范围在 $\{1, \dots, [T/2]\}$ 。基于选取到的 Top k 频率分量 $\{f_1, \dots, f_k\}$ 和对应的周期长度 $\{p_1, \dots, p_k\}$ ，可以将一维时间序列 $X_{1D} \in \mathbb{R}^{T \times C}$ 转为二维张量，转换计算如式 2.8。

$$X_{2D}^i = Reshape_{p_i, f_i}(Padding(X_{1D})), i \in \{1, \dots, k\} \quad (2.8)$$

其中 $Padding(\cdot)$ 为序列长度不满足转换需求的长度，从而需要延长序列，向其填充 0，最终得到转换拼接后的二维张量。这种转换模式可以让模型捕捉到相邻时间点即周期内的变化趋势和相邻周期期间的特征，便于通过二维方法提取序列特征。一维时序变量转为二维张量的过程如图 2-11 所示。

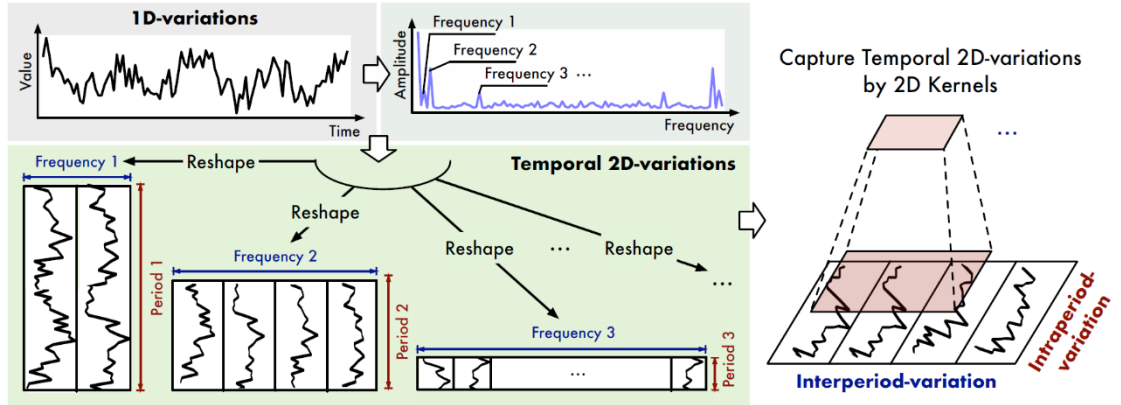


图 2-11 一维时序变量转为二维张量

Times Block

为了避免梯度消失与梯度爆炸问题，Times Block 采用残差连接，具体结构如图 2-12 所示。

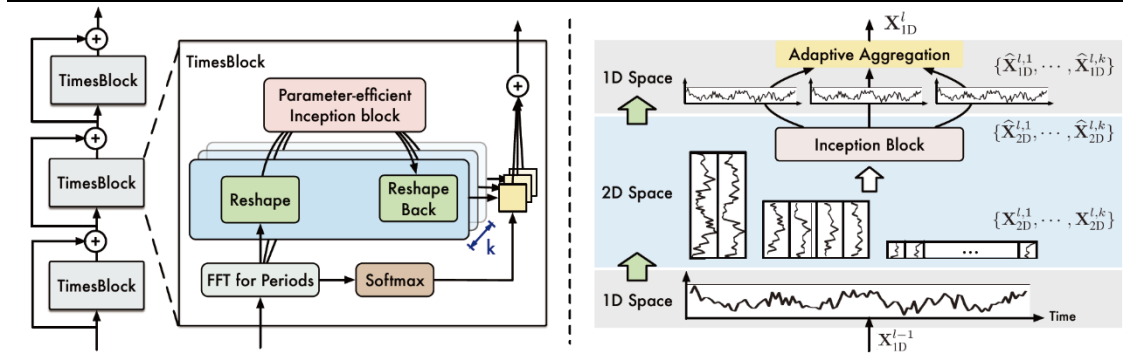


图 2-12 Times Block 模块结构

对于任意输入长度为 T ，变量数为 C 的时间序列 $X_{1D} \in \mathbb{R}^{T \times C}$ ，通过嵌入层获取其深层特征，并将其投射为 $X_{1D} \in \mathbb{R}^{T \times d_{model}}$ 。对于任意 1 层的 Times Block，其与输入 1-1 层的关系可如式 2.9 所示。

$$X_{1D}^l = \text{TimesBlock}(X_{1D}^{l-1}) + X_{1D}^{l-1} \quad (2.9)$$

如图 2-12 所示，Times Block 主要由两部分组成二维特征获取与自适应聚合。通过式 2.7 获取到序列周期长度，从而获取周期信息，进而将一维时间序列转为二维张量。从而通过参数高效的 inception 模块(parameter-efficient inception block)获取二维张量及时序周期信息的深层特征。该过程可如式 2.10 表示。

$$\begin{aligned} A^{l-1}, \{f_1, \dots, f_k\}, \{p_1, \dots, p_k\} &= \text{Period}(X_{1D}^{l-1}), \\ X_{2D}^{l,i} &= \text{Reshape}_{p_i, f_i}(\text{Padding}(X_{1D}^{l-1})), i \in \{1, \dots, k\} \\ \hat{X}_{2D}^{l,i} &= \text{Inception}(X_{2D}^{l,i}), i \in \{1, \dots, k\} \\ \hat{X}_{1D}^{l,i} &= \text{Trunc}(\text{Reshape}_{1, (p_i \times f_i)}(\hat{X}_{2D}^{l,i})), i \in \{1, \dots, k\} \end{aligned} \quad (2.10)$$

其中 $X_{2D}^{l,i}$ 为第 i 个转换后的二维张量，然后通过 $\text{Inception}(\cdot)$ 模块提取模型特征，得益于将原始序列转为二维张量，可以通过计算机视觉中的模块提取时间序列中的周期内特征，即拼接后二维张量的行，与周期间特征，拼接后二维张量的列。然后将学习后的二维特征 $\hat{X}_{2D}^{l,i}$ 重新拼接为一维特征 $\hat{X}_{1D}^{l,i}$ ，其中 $\text{Trunc}(\cdot)$ 用于去除序列中填充的 0，最终得到原始的序列长度 T 。

基于 YOLO11 的火焰目标检测原理分析

在火焰目标检测的任务中，实时性和准确性是两个至关重要的指标。火焰作

为一种动态且不规则的目标，具有形态多变、颜色复杂以及边界模糊的特点，因此采用 YOLO11 作为核心检测模型。相比于传统的目标检测算法，YOLO 系列通过端到端的单阶段检测架构，大幅减少了计算复杂度，从而实现较高推理速度，这对于火焰检测场景中需要快速响应的应用尤为重要。

YOLO11 保持 YOLO 系列结构，通过初始卷积层对图像进行下采样，实现基础的特征提取，逐渐减少空间维度，增加通道数量。YOLO11 的重大改进是引入了 C3K2 模块，C2PSA 模块，YOLO11 模块如图 2-13 所示。

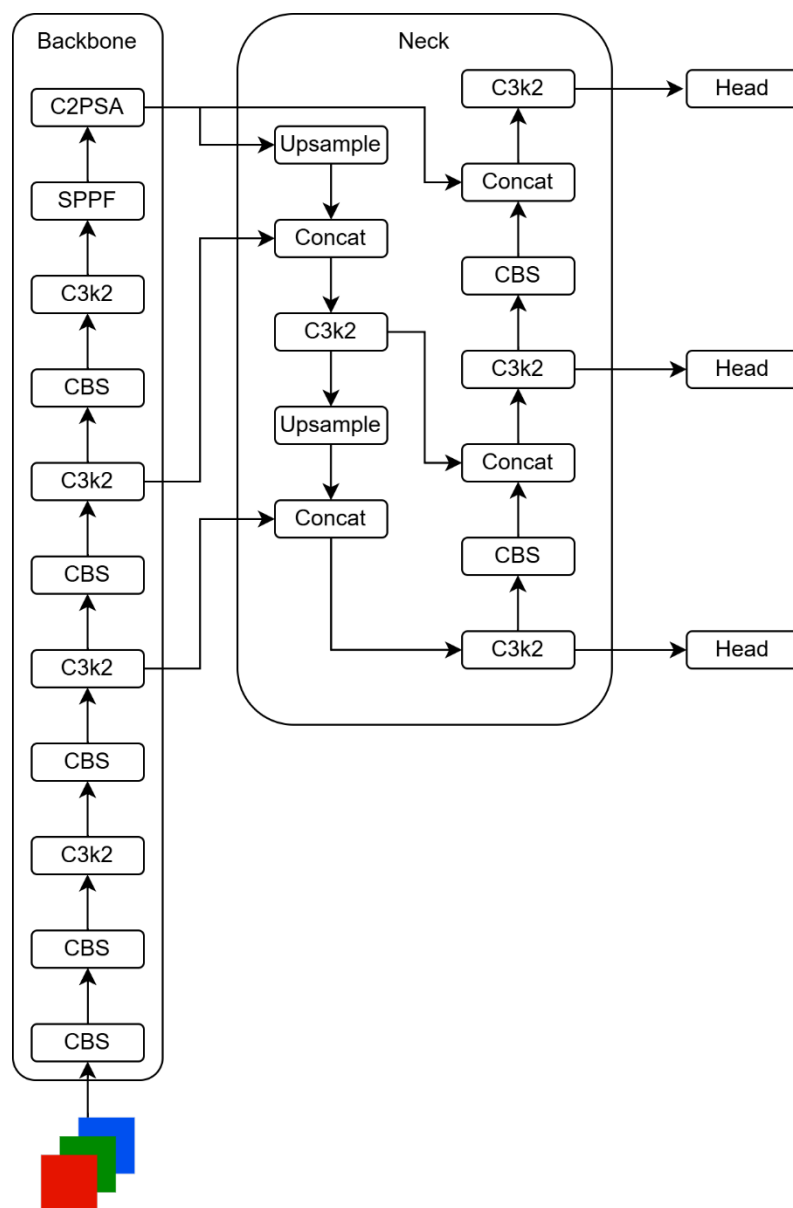


图 2-13 YOLO11 网络结构

将原来的 C2f 模块替换为 C3K2 从而提高计算效率，其采用两个较小的卷积模块而不是 C2f 中的大卷积，从而更快、更高效的实现特征提取。C3k2 模块如图 2-14 所示。

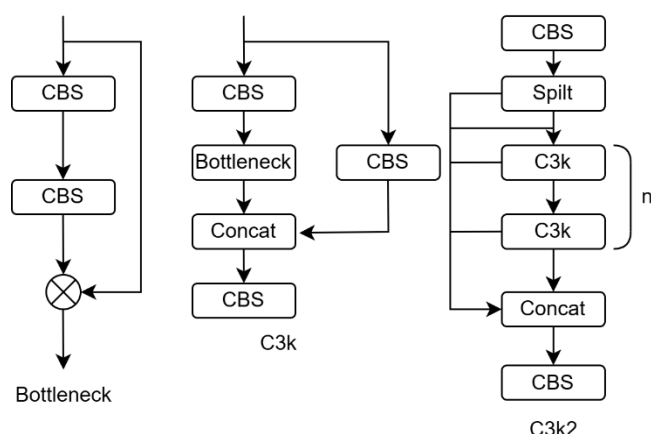


图 2-14 C3k2 模块结构

C2PSA 是对 C2f 模块的扩展，其结合了 PSA(Pointwise Spatial Attention)，用于特征提取的注意力机制。通过引入 PSA 块，这种空间注意力机制使模型能够更有效地关注图像中的重要区域。通过在空间上集中特征，C2PSA 提高了对重要特征的捕捉能力，使得模型能够集中注意在特定的感兴趣区域，从而提高对不同大小物体检测准确性，特别是对于较小或部分被遮挡的对象，这对火焰检测至关重要，C2PSA 模块如图 2-15 所示。

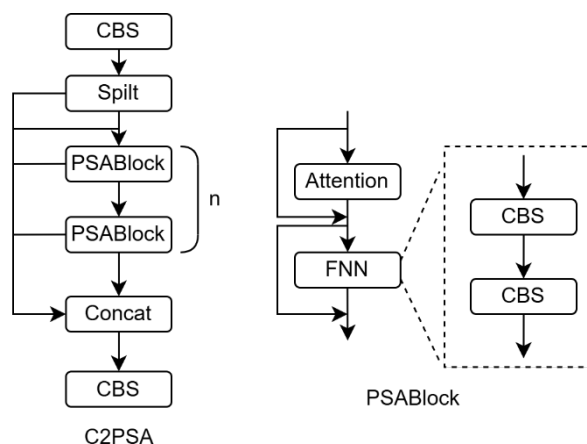


图 2-15 C2PSA 模块结构

第三部分 完成情况及性能参数

3.1 整体介绍



图 3-1 实物整体照片

3.2 工程成果（分硬件实物、软件界面等设计结果）

3.2.2 电路成果；




图 3-2 自主硬件设计实物图

3.2.3 软件成果；




图 3-3 软件主界面展示

3.3 特性成果（逐个展示功能、性能参数等量化指标）


3.3.1 硬件系统特性成果

该部分在实际运行环境下的数据采集性能及信号处理能力进行了验证与分

析。测试过程中，硬件平台集成了温度传感器、电流采样模块，分别用于获取系统的环境温度、负载工作电流等关键参数。如图 3-4 所示，展示了两个负载采集到的缩放后的电流原始波形及其经过滤波处理后的结果，可以看出系统具备良好的抗干扰能力，能够有效抑制噪声并保留信号的主要特征。



(a)



(b)

图 3-4 电流采样及滤波后的波形

原始数据采集完成后，提取了多个特征，以揭示系统状态的动态变化规律。采用快速傅里叶变换方法提取频谱能量、主频分布及其幅值变化，从提取负载的频域特征。某负载的频域特征如图 3-5 所示。可见模型的频域提取的特征虽然每次接入提取的特征值略有不同，单误差在允许范围内。且总体趋势趋于一致。



3-5 某负载的频域特征提取

从整体测试结果来看，系统具备较强的数据采集稳定性，特征变化规律与实际运行状态高度一致，验证了硬件平台在长期运行条件下的可靠性与适应性。

3.3.2 软件特性成果

如图3-6所示，大数据平台界面直观展示了当前平台的基本信息及充电情况，涵盖设备管理、资金管理、订单管理和实时充电记录等功能模块。管理端用户可以清晰查看各充电桩的使用状态、订单数量及收入数据，实现对整体运营情况的全面掌控。同时，通过实时充电记录中的充电状态监控，系统能够及时发现异常充电口，便于运维人员快速定位并处理故障，提高管理效率与服务质量。



3-6 大数据平台界面

如图 3-7 所示，后台管理平台主要包括设备管理、订单管理和资金管理三

大模块，支持对充电设备的全面监控与管理。其中，设备管理模块可查看每个充电桩的详细信息，包括总成交金额、订单数量及安装地点等，同时还能实时监控各充电桩下充电口的状态，具体分为使用中、空闲、离线和异常四类，便于用户直观掌握设备的运行情况，提升运营效率与管理便捷性。

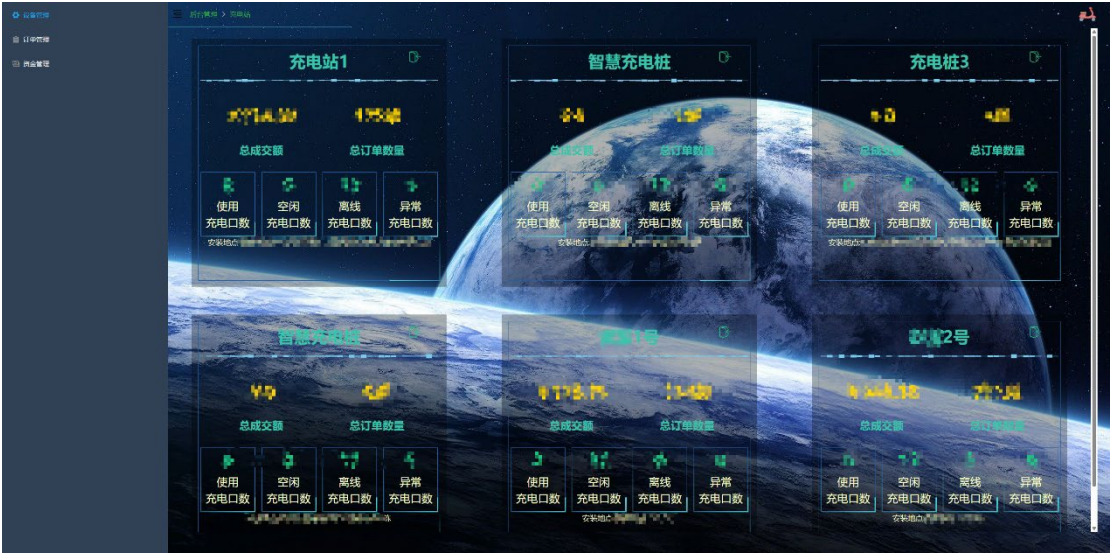


图 3-7 后台管理平台

图 3-8 所示为订单管理界面，用户可在该界面查看订单时间、订单编号、充电桩及充电口编号、订单状态、金额、接入设备类型等详细信息，实时掌握订单是否完成或处于异常状态。系统还支持识别接入设备类型，如铅酸电瓶或锂电池，为后续实现分区域、分类管理提供数据基础，进一步提升平台的精细化运营能力。

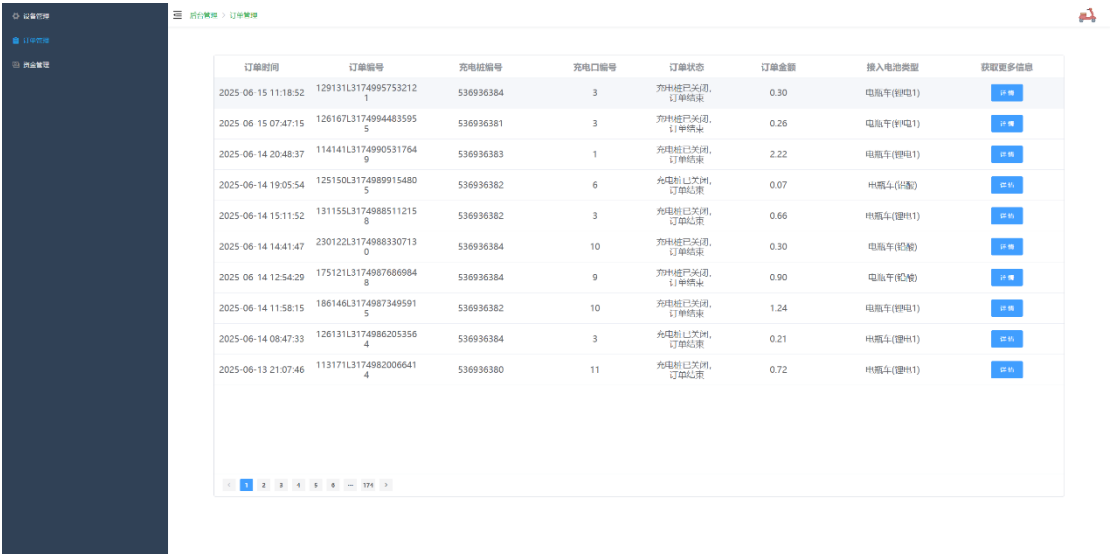


图 3-8 订单管理界面

图 3-9 为订单详情页面，用户在订单管理界面中点击某一订单的“详情”按钮即可进入该页面。在此界面中，系统以更直观清晰的方式展示了订单的各项详细信息，便于用户进行数据核查、问题追溯及后续管理操作。

图 3-10 展示的是资金管理界面，页面支持查看当日、本周、本月及累计交易金额，帮助用户全面掌握平台资金流入情况。同时，用户可通过界面下方的提现功能，根据所选日期快速进行按月提取操作，实现资金管理的灵活性与便捷性。



图 3-9 订单详情页面

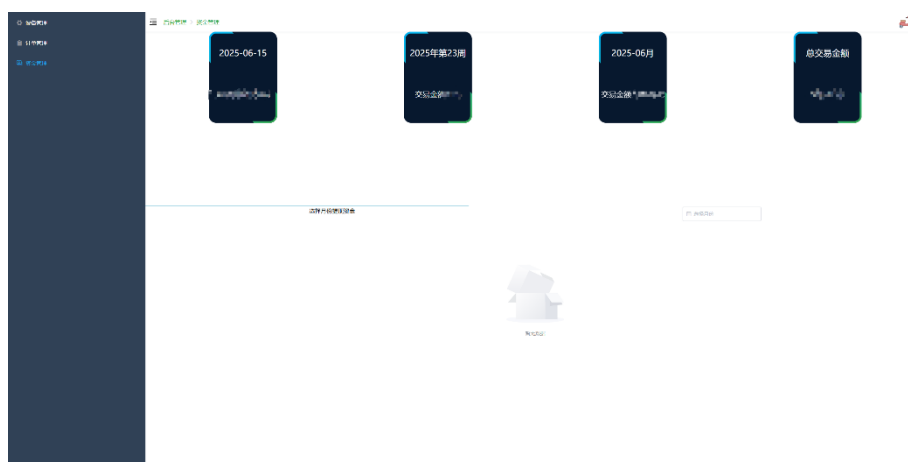


图 3-10 资金管理界面

同时平台集成了火焰检测视频监控，如图 3-11 所示为火焰目标检测监控视频。




图 3-11 火焰检测平台显示

用户端小程序

为了更好的引导用户完成充电流程，同时减少人工客服的运营成本，我们引入了大语言模型的智能对话客服，从而帮助用户熟悉充电流程，如图 3-12 所示。用户端小程序作为本系统面向用户的交互界面，主要用于提交充电订单、展示设备运行状态等。系统确认订单生成后，若触发报警便能在第一时间将告警信息推送至用户小程序界面，用户无需登录后台即可便捷获取关键预警内容，实现快速响应。同时，小程序具备良好的兼容性和稳定性，支持主流安卓与 IOS 设备，界面简洁、操作流畅，能够在不同网络环境下稳定运行，满足火灾预警系统对时效性和可靠性的要求。经过测试，各项功能表现正常，能有效辅助用户实现远程监控与及时应对火灾风险。如图 3-13 所示。



3-12 基于大语言模型智能对话客服



(a)



(b)



(c)

图 3-13 小程序操作界面

第四部分 总结

4.1 可扩展之处

现有系统依赖电流/电压特征与视觉火焰检测，可在此基础上扩展多模态传感融合，引入红外热成像、CO/烟雾气体传感器等模块，实现电池热失控的早期预警，全面提升火灾防控能力。在应用层面，非侵入式识别技术可迁移至电动摩托车、三轮车等充电场景，或适配家庭储能设备监测，扩大技术覆盖面。进一步地，可基于历史充电数据构建电池健康度评估模型，实现电池寿命预测及预防性维护，并与保险机构联动，按用户安全评分制定差异化保费方案。此外，通过集成分时电价策略、光伏储能协同调度等能源管理功能，引导用户错峰充电，降低电网压力，提高充电桩经济性与环保价值。为提升全局优化与泛化能力；

4.2 心得体会

项目在技术路线的推进过程中，经历了从算法优化到系统集成多轮迭代。起初，团队将重点放在算法指标提升，通过在实验室环境中反复进行模型

训练和数据增强，力求实现更高的检测精度。然而，当模型进入实地测试阶段时，复杂环境带来的挑战逐渐显现，例如昏暗楼道中红色衣物被误判为火焰，以及铅酸电池与充电器老化产生的谐波干扰导致异常检测结果频繁漂移。这些问题暴露了算法在真实场景下的适应性不足，促使团队调整技术路径。

针对复杂环境下的干扰因素，团队提出了双分支模型架构，将传统非参数聚类方法与深度时序模型相结合。首先，在算法层引入 HDBSCAN 非参数聚类方法，实现对原始数据的毫秒级初筛，用于快速过滤无关噪声和信号；随后通过 TimesNet 深度学习模型建模时序特征，对初步筛选结果进行进一步分析和修正，有效降低了误报和漏报率。整体数据流在 RK3588 边缘计算芯片上进行推理，并结合轻量化技术优化模型结构和计算性能，将推理延迟控制在严格的范围内，从而确保系统在弱网甚至断网环境下也能实现本地化独立预警。

硬件层面同样经历了多轮优化，最终选择集成 HLW8110 计量芯片以提升电气参数检测的精度，并配合磁保持继电器实现无源断电保护，保证设备即插即用的便捷性与长期稳定运行。软件架构在保证边缘侧实时性的同时，设计了分级告警机制，使本地事件处理与云端管理协同工作。同时在用户交互方面，嵌入基于 LLM 的智能客服模块至小程序，实现充电桩主动推送电池状态、健康建议等功能，形成用户侧闭环。

这一整套软硬件协同体系，使系统在复杂多变的实际环境中具备高可靠性和快速响应能力，为社区高密度部署提供了技术支撑，也确保了充电过程中的安全预警能够最大程度发挥效用。

4.3 总结

本项目面向当前电动自行车引发火灾频发、用电安全隐患突出的社会问题，提出并实现了一套融合非侵入式负载识别与智能火焰检测的综合安全监测系统。通过自研硬件平台与创新性的双模型识别架构，系统在无需改造现有充电环境的前提下，能够实现对不同电池类型及其运行状态的精准识别，有效监测故障电弧、异常漏电等高风险因素。

在算法设计上，项目将非参数统计方法与深度学习模型相结合，兼顾识别效率与准确率，并通过边缘计算设备实现本地智能识别与火灾快速响应，大幅

提升了系统的实时性与鲁棒性。系统平台采用分布式架构，确保数据处理的高并发、高可用，并提供完善的多终端可视化交互界面，全面提升用户体验与运维效率。

经过多地实际部署验证，系统稳定性强、识别准确率高，已获得多家电动自行车充电运营商和相关管理单位的广泛认可，具备良好的推广应用前景。项目为构建智能、安全、高效的电动自行车充电管理体系提供了重要技术支撑，体现了人工智能在公共安全领域的深度融合与落地能力。

第五部分 参考文献

- [1] 周宝庆, 朱锦波, 高林峰. 锂离子电池热失控及灭火技术综述 劳动保护 [J]. 2024, (10): 68-70.
- [2] HART G W J P O T I. Nonintrusive appliance load monitoring [J]. 1992, 80(12): 1870-91.
- [3] BOUHOURAS A S, GKAITATZIS P A, PANAGIOTOU E, et al. A NILM algorithm with enhanced disaggregation scheme under harmonic current vectors [J]. 2019, 183: 392-407.
- [4] SU Y-C, LIAN K-L, CHANG H-H. Feature selection of non-intrusive load monitoring system using STFT and wavelet transform; proceedings of the 2011 IEEE 8th international conference on e-business engineering, F, 2011 [C]. IEEE.
- [5] LAM H Y, FUNG G, LEE W J I T O C E. A novel method to construct taxonomy electrical appliances based on load signaturesof [J]. 2007, 53(2): 653-60.